REPRODUCTION STUDY · 2026-10-20

pBAE 细胞摄取预测
补齐基因、重跑四模型、对比 Table 2

已完成缺失基因恢复和四模型训练。恢复了论文所列的 17 个特征，并按公开最终参数运行；这属于有来源与校验记录的近似复现，仍不能宣称精确重现论文实验。

复现代码、数据与结果： https://github.com/RuiyuM/pbae-cellular-uptake-reproduction

240	17	212 / 212	16
原始摄取样本	重建模型输入	表达值校验通过	完整 NN 训练

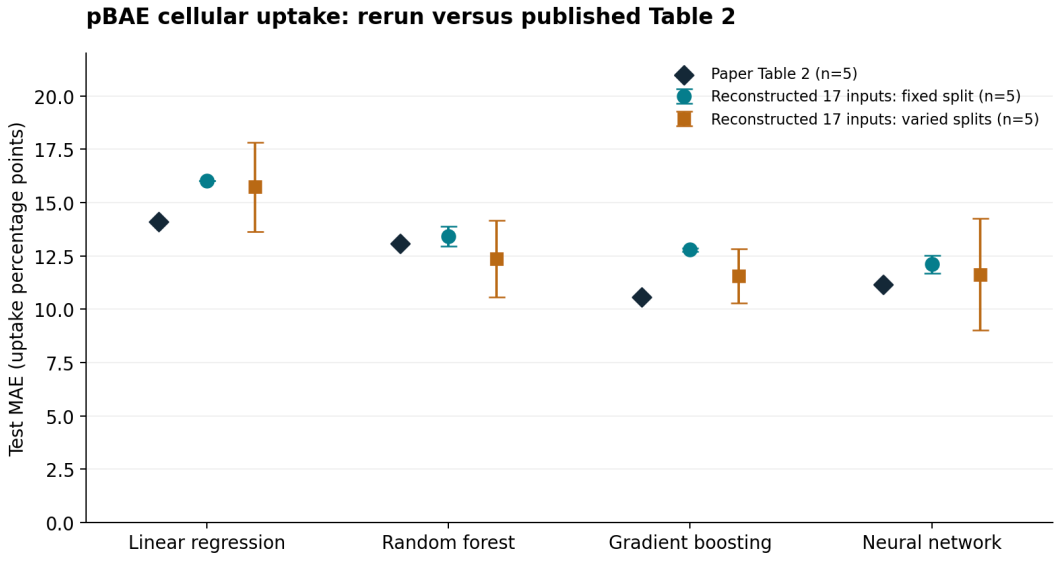
与论文 Table 2 的对比

指标为测试集平均绝对误差 MAE，单位是摄取率的百分点，越低越好。我们的 ± 为 5 次运行的样本标准差，不能直接当作置信区间。论文 Table 2 仅提供 5 次平均值。

模型	论文 Table 2	固定划分：均值 ± SD	更换划分：均值 ± SD	固定划分相对论文差值
线性回归 LM	14.09	16.03 ± 0.00	15.74 ± 2.09	+1.94
随机森林 RF	13.09	13.42 ± 0.45	12.36 ± 1.79	+0.33
梯度提升树 GBT	10.57	12.79 ± 0.08	11.55 ± 1.27	+2.22
神经网络 NN	11.17	12.10 ± 0.43	11.64 ± 2.62	+0.93

固定划分沿用仓库的划分种子 7，只改变模型随机种子 7–11；**更换划分**使用划分种子 7–11，并使用对应模型种子。每次均为 192 条训练、24 条验证、24 条测试。所有结果均保留，没有筛选最接近论文的一次。

固定划分下，RF 与论文均值差 +0.33，NN 差 +0.93，GBT 差 +2.22。更换划分后的 GBT 和 NN 均值接近，但波动明显；这不能证明与论文具有统计等价性。



Error bars: sample SD, not confidence intervals. Paper Table 2 supplies means only.
Reconstructed inputs and documented assumptions; not an exact recovery of the published experiment.

缺失基因找到了什么

从论文列出的四个 GEO 原始芯片文件中，恢复了缺失的 CLTA、CLTB、CLTC、PICALM，并重新提取 CAV1、CAV2。没有使用零值、随机值或从热图估读的数值填补。

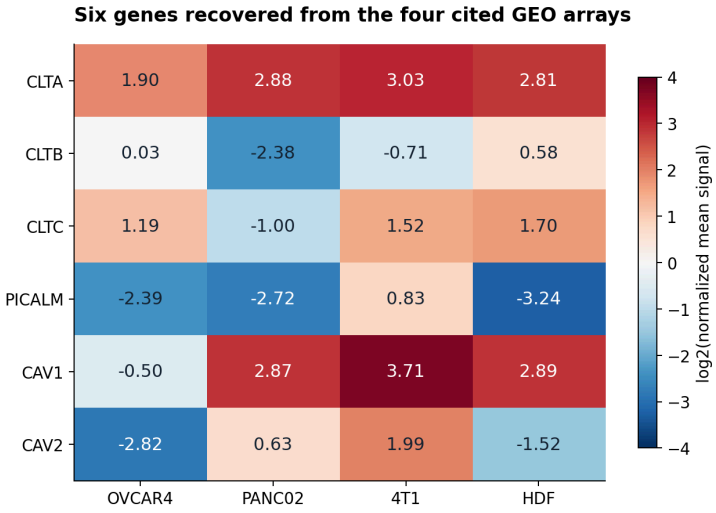
- OVCAR4：GSM564167
- PANC02：GSM1406256
- 4T1：GSM1529765
- HDF：GSM613188

通过已有 53 个基因 × 4 类细胞反向校验，以下处理规则在 212 个数值上全部匹配当前作者仓库，最大绝对误差 `1.15e-14`：

```
expression = log2(median(所匹配探针的 gMeanSignal)
                 / mean(整张芯片所有点的 gMeanSignal))
```

匹配规则为不区分大小写的基因名称子串匹配；HDF 的 AGRIN 使用别名 AGRN。该规则由可验证数据推断得到，作者未公开对应预处理脚本。

细胞	CLTA	CLTB	CLTC	PICALM	CAV1	CAV2
OVCAR4	1.902405	0.027273	1.185078	−2.391081	−0.501232	−2.818126
PANC02	2.879738	−2.378299	−0.996430	−2.723693	2.873892	0.628098
4T1	3.029336	−0.714268	1.523971	0.832048	3.711449	1.990508
HDF	2.813430	0.578826	1.702805	−3.243042	2.888049	−1.515759

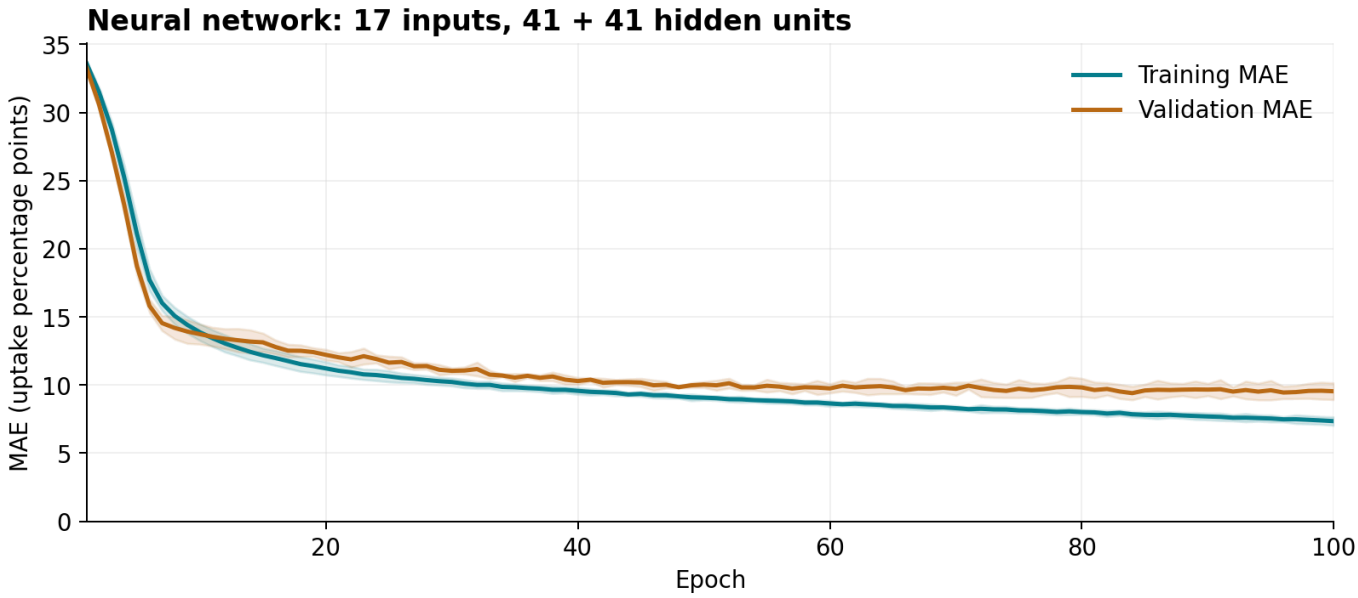


Repository-compatible matching; CLTC also matches CLTCL1 in human arrays.
The mouse CAV1/CAV2 directions differ from the published Figure 3B.

重要限制：该恢复过程匹配的是当前仓库的表达数据。恢复的两种小鼠细胞 CAV1/CAV2 方向与论文 Figure 3B 的颜色不一致；论文最终的六基因输入矩阵和具体探针选择仍未找到。我们保留原始来源计算值，没有人为调整数据以贴近论文。

本次采用的训练设置

- 输入：6 个聚合物比例、Size、Polydispersity、6 个基因，以及癌变、转移、人类物种三个二元特征。细胞身份只用于合并和记录，不额外作为特征。
- RF：75 棵树、最大深度 13；未公开的 `max_features` 沿用仓库的 `sqrt`。
- GBT：50 棵树、最大深度 5、学习率 0.1。
- NN：17 → 41 ReLU → 41 ReLU → 1 线性输出；RMSprop 学习率 0.001，MSE 损失，batch size 5，100 epochs。优化器和批大小取自作者最终训练代码。
- 所有标准化统计量仅从训练集计算。使用最后一轮 NN 模型，不根据测试结果选轮次，不裁剪预测值。直接使用论文已报告参数，没有重做历史调参搜索。
- 环境：Python 3.10.18，scikit-learn 1.2.2，TensorFlow/Keras 2.10.0，NumPy 1.23.5，SciPy 1.10.1；CPU 训练。



Mean and sample SD over five initializations; fixed split=7. Final epoch evaluated, no test-based epoch selection.

未公开细节与敏感性检查

论文正文称 NN 输入层为 9 个节点，但 Figure 5 明确列出 17 个特征；本次采用 17 个特征。论文没有给出 5 次实验的种子和重复方式，因此同时报告固定划分和更换划分。期刊旧补充材料地址在本次下载时返回 404，备用地址返回 403。

基因匹配

与当前仓库一致的子串匹配会把人类的 CLTCL1 也匹配到 CLTC。我们另外运行了精确名称匹配，以单独显示这一影响；没有根据测试效果选择主结果。

模型	作者兼容匹配	精确基因名称匹配
LM	16.03 ± 0.00	15.97 ± 0.00
RF	13.42 ± 0.45	13.35 ± 0.47
GBT	12.79 ± 0.08	12.70 ± 0.06
NN	12.10 ± 0.43	11.90 ± 0.37

随机森林未公开参数

将 `max_features` 改为 1.0 的额外对照，固定划分 MAE 为 12.80 ± 0.58。该参数足以改变与论文的数值差距，因此不能仅靠调到接近 13.09 就宣称复现成功。

线性回归的数值稳定性

这些特征存在共线性：配方比例总和固定，细胞相关表达只有四组独特取值。原版 scikit-learn 的求解产生很大的系数。保持报告的 LM 结果不变，同时提供了单独的稳定 SVD 诊断；固定划分的稳定解 MAE 为 15.92。这也是旧库版本及特征排列可能影响复跑数值的原因。

验证与可重跑文件

已检查全部 1,536 条测试预测与报告 MAE 一致，16 组划分互不泄漏，16 次 NN 均训练满 100 轮。相同数据与种子的独立运行预测完全一致；保存的 NN 重新载入后能重现预测。

- 全部对比结果 CSV / 逐次实验结果 / 测试预测
- 重建的 240 × 17 数据 / 六基因表达数据
- 212 项归一化校验 / 逐探针来源
- 实验配置与假设 / 结果校验记录 / 运行说明

获取代码与重新运行

打开以下仓库，点击 Code → Download ZIP 即可下载完整代码包。仓库同时保存本报告 PDF、处理后的输入、逐次结果与校验记录。

> https://github.com/RuiyuM/pbae-cellular-uptake-reproduction

运行环境与顺序见仓库首页 README。先下载固定版本的作者仓库及 GEO 原始数据，再依次重建特征、训练、校验和生成报告。原始芯片及作者论文通过来源下载，不随代码包重复打包。

数据来源、文件校验值和具体假设见 sources/download_manifest.json、results/input_checksums.json 与 results/protocol.json。

论文：A machine learning approach to predict cellular uptake of pBAE polyplexes, DOI 10.1039/D3BM00741C。论文 PDF · 期刊页面 · 作者仓库。作者仓库固定提交：15e8e34a062f023cb1844fe5762d32f459bc1ef0。本报告为独立复现，未联系作者。
复现项目：https://github.com/RuiyuM/pbae-cellular-uptake-reproduction